

HR Attrition — Predykcja odejść pracowników

Projekt Data Science: EDA · Feature Engineering · Modele klasyfikacji · Clustering

- Zbior: IBM HR Analytics (1470 pracowników, 16% Attrition)
- Modele: Logistic Regression, SVM, Random Forest, XGBoost, MLP, TF Neural Network, Voting, Stacking
- Feature engineering: 88 cech (v1/v2/v3/v4)
- Wyniki: F1=0.598 (Voting LR+SVM), AUC=0.821

Agenda

01

Analiza eksploracyjna danych (EDA)

02

Feature Engineering — 88 cech

03

SMOTE vs class_weight

04

Modele klasyfikacji

05

Feature Importance per model

06

Ensemble: Voting i Stacking

07

Wyniki — TRAIN vs TEST, obie klasy

08

Najlepszy model + Clustering

01. Analiza eksploracyjna danych (EDA)

IBM HR Analytics — 1470 pracowników, 35 cech surowych

Zbior danych

1470 pracowników · 35 kolumn · 0 braków danych

Klasa docelowa

Attrition=1 (odejście): 237/1470 = 16.1% — silna nierówność

Cechy kategoryczne

7 kolumn: BusinessTravel, Department, Gender, JobRole, ...

Cechy numeryczne



28 kolumn: Age, MonthlyIncome, YearsAtCompany, ...

Kluczowe korelaty

OverTime (P=0.25), MaritalStatus=Single, JobLevel niski, dystans od domu wysoki, krótki staż u menedżera

Rozkłady


MonthlyIncome: prawoskłonny · Age: normalny
Attrition=1 wyraźnie młodszy i gorzej zarabiający




01. Analiza eksploracyjna danych (EDA)

IBM HR Analytics — 1470 pracowników, 35 cech surowych


P(Attrition=1) wg OverTime




P(Attrition=1) wg Department




P(Attrition=1) wg JobRole



P(Attrition=1) wg MaritalStatus



P(Attrition=1) wg BusinessTravel



02. Feature Engineering — 88 cech wejsciowych

19 cech v1/v2 + 17 v3 + 12 v4 + 7 OHE kategoriycznych

v1/v2 — Stabilnosc i kariera (19 cech)

- IncomePerYearExp
- CompanyTenureRatio
- RoleStabilityRatio
- PromotionIntensity
- OvertimeLowSat
- TravelBurden
- ...


v3 — Ryzyko i wypalenie (17 cech)

- BurnoutRiskScore
- StabilityComposite
- TravelFatigue
- CommuteRisk
- FrequentJobSwitcher
- SatisfactionVariance
- ...

v4 — Zaangazowanie i opcje (12 cech)

- LowJobInvolvement
- NoStockOptions
- StockRetentionRisk
- TotalDissatisfaction
- InvolvementXSatisfaction
- ...


Top-12 cech — Logistic Regression (|coef|)



03. Niezbalansowanie klas — SMOTE vs class_weight

16% klasy Attrition=1 — kluczowa decyzja architektoniczna

Strategie balansowania klas



Model	Metoda balansowania	Uzasadnienie
LR, RF, BRF	SMOTE (strategy=1.0)	Wymaga pełnego balansowania dla konwergencji
SVM	class_weight='balanced'	SMOTE powodował overfitting ($\Delta F1=0.19 \rightarrow 0.06$)
MLP (sklearn)	class_weight w loss	SMOTE powodował overfitting ($\Delta F1=0.46 \rightarrow 0.22$)
TF Neural Net	class_weight w fit()	Jak MLP — class_weight bardziej stabilny
XGBoost	scale_pos_weight=5.2	Natywne wazenie, SMOTE nie potrzebny
Stacking	Osobne strategie czlonkow	Kazdy bazowy model ma swoja strategie

04. Modele klasyfikacji — architektura pipeline

engineer(features) → [select_top20] → preprocess(OHE) → [SMOTE] → [scaler] → model

Logistic Regression

L2/ElasticNet, C=0.001
SMOTE 1.0, StandardScaler

SVM

RBF/linear, C=0.001
class_weight='balanced'
StandardScaler

Random Forest

BRF, max_depth=4
min_samples_leaf=15
SMOTE 1.0

Balanced RF

BRF sampling_strategy='all'
max_depth=4
SMOTE 1.0

XGBoost

max_depth=1-3
scale_pos_weight=5.2
Early stopping (36 iter)

MLP sklearn

arch=(32,)
alpha=0.3, tanh
class_weight, early stop

TF Neural Net

Dense(64→32→16)
Dropout=0.3, BN, L2=0.01
class_weight, patience=20

Stacking LR+SVM

Baza: LR + SVM
Meta: LR (C=0.1)
5-fold CV probabilities

Wspólny krok 0: FeatureEngineeringTransformer — pipeline jest samowystarczalny (surowe dane → predykcja)


05. Feature Importance — co napędza predykcję odejść?

Metoda ważności cech dobrana do klasy modelu | Normalizacja [0,1] per model

Logistic Regression

|coef_| (ElasticNet)


Top-10 — LR



RF / Balanced RF

Gini impurity (mean decrease)


Top-10 — RF



XGBoost

Gain (information gain per split)

Top-10 — XGB



SVM / MLP

Permutation importance (F1)

Top-10 — SVM



Cechy wspólne dla wszystkich modeli:


- OverTime / OvertimeLowSat — praca w nadgodzinach to najsilniejszy predyktor
- StockDissatisfactionRisk / NoStockOptions — brak opcji akcji + niezadowolenie
- InvolvementXSatisfaction — iloczyn zaangażowania i satysfakcji
- CompaniesPerYear / FrequentJobSwitcher — historia zmian pracodawców
- Age + MonthlyIncome — młodzi i nisko opłacani odchodzą najczęściej

05b. Porównanie ważności cech między modelami

Normalizacja [0,1] per model | Top-15 wg średniej rangi | czerwony = wysoka ważność


05a. Ensemble — Voting LR+SVM (najlepszy model)

Soft voting: usrednienie prawdopodobienstw $P(\text{Attrition}=1)$




Metryka	LR (solo)	SVM (solo)	Voting LR+SVM
F1 (Rezygnuje)	0.595	0.591	0.598 ✓
Precision	0.611	0.556	0.560
Recall	0.579	0.632	0.642
ROC-AUC	0.824	0.816	0.821
Overfit ΔF1	0.095	0.057	0.061

Dlaczego voting wygrywa: LR ma wyższa Precision (0.611), SVM wyższa Recall (0.632) — usrednienie kompensuje slabosci i daje lepszy F1 niz kazdy z osobna.



05b. Stacking LR+SVM — meta-learner



Stacking 2-poziomowy: LR + SVM jako baza, LR jako meta-klasyfikator



	Stacking BRF+XGB+CB	Stacking LR+SVM
CV (ROC-AUC)	0.548	0.698 ✓
F1_TEST	0.278	zbieżny z LR/SVM
Recall=1.0?	TAK (zdegenerowany)	NIE — poprawion

06. Wyniki wszystkich modeli — TRAIN vs TEST



Zbiór testowy: 588 próbek · Attrition=1: 95 (16.2%)



Model	F1_tr	F1_te (Rej.)	F1_te (Zos.)	Prec	Recall	AUC	Overfit
Voting LR+SVM	0.659	0.598	0.916	0.560	0.642	0.821	0.061
Logistic Regression	0.690	0.595	0.924	0.611	0.579	0.824	0.095
SVM	0.648	0.591	0.915	0.556	0.632	0.816	0.057
Voting LR+SVM+MLP	0.712	0.569	0.909	0.532	0.611	0.818	0.143
TF Neural Network	0.926	0.520	0.899	0.486	0.558	0.764	0.406
MLP (sklearn)	0.726	0.510	0.872	0.419	0.653	0.803	0.216
Random Forest	0.624	0.504	0.879	0.430	0.611	0.792	0.120

06b. Wyniki per klasa — Zostaje (0) vs Rezygnuje (1)

Klasa 1 (Rezygnuje) to glówny cel predykcji — kosztowna pomyłka: FN



Interpretacja biznesowa

FN (False Negative) = pracownik odejdzie a model nie przewidzi

→ koszt: utrata talentow,
rekrutacja (6-9x miesieczna pensja)

FP (False Positive) = falszywy alarm
→ koszt: zbedna retencja (~500 zl)

Optymalny model: wysoki Recall
bez za duzej liczby FP

Voting LR+SVM:
TN=450, FP=43, FN=33, TP=62
Recall=0.642 — wykrywa 62/95

07. Najlepszy model — Voting LR+SVM

F1=0.598 · AUC=0.821 · Overfit=0.061 · TN=450, FP=43, FN=33, TP=62

F1 (Rezygnuje)

0.598

Precision

0.560

Recall

0.642

ROC-AUC

0.821


Accuracy

0.861


Overfit $\Delta F1$

0.061

Macierz pomylek
(TEST, 588 probek)



F1 vs próg decyzyjny (val)




Wnioski

- Voting LR+SVM przewyższa oba modele solo (+0.003/+0.007 F1)
- Najniższy overfit wśród ensembli ($\Delta F1=0.061$ vs voting 3-czl. 0.144)
- Wykrywa 62/95 odejść (Recall=64%)
- Prog OOF = 0.53 — uczciwy, bez przecieku na dane testowe
- Realny pułap F1: ~0.56-0.65 (syntetyczny zbiór 1470 prob.)

08. Clustering pracowników — KMeans k=4

Segmentacja 1470 pracowników na 21 cechach numerycznych

Klaster 0: Nomadzi	Klaster 1: Starterzy	Klaster 2: Lojalni Stagnujący	Klaster 3: Seniorzy
N = 447 (30%) Attrition: 19% Ryzyko HR: Srednie Wysoka mobilnosc (5 firm) Sredni wiek 36 lat Krotki staz ~3 lata	N = 431 (29%) Attrition: 22% NAJWYZSZY Ryzyko HR: WYSOKIE Mlodzi ~30 lat Najnizsze zarobki \$3380 Pierwsza lub druga praca	N = 407 (28%) Attrition: 10% Ryzyko HR: Niskie Dlugi staz ~10 lat Brak awansu >4 lata Niska mobilnosc historyczna	N = 185 (13%) Attrition: 9% najnizszy Ryzyko HR: Niskie Najstarsi ~47 lat Najwyzsze zarobki \$15490 Menagerscy/dyrektorzy



Rekomendacje HR per segment

- Starterzy (PRIORYTET): podwyzki entry-level · buddy/mentoring · awanse
- Nomadzi: jasna sciezka kariery · projekty z nowymi kompetencjami
- Lojalni Stagnujący: lateral moves · programy uznaniowe · nowe projekty
- Seniorzy: mentoring odwrocony · elastyczne formy pracy · sukcesja

Podsumowanie projektu HR Attrition

EDA

1470 pracowników · 16% Attrition
OverTime, JobLevel, staz — klucz. predyktory

Feature Eng.

88 cech: 19(v1/v2) + 17(v3) + 12(v4) + OHE
BurnoutRiskScore, StabilityComposite, TravelFatigue

Modele

8 modeli bazowych + warianty top-20
LR/SVM najlepiej generalizują

SMOTE

LR/RF: SMOTE 1.0 | SVM/MLP/TF: class_weight
Eliminacja overfittingu SVM: 0.19→0.06

Najlepszy

Voting LR+SVM F1=0.598 AUC=0.821
Overfit=0.061 · Recall=0.642

Clustering

4 segmenty · Starterzy (22% Attrition)
59% zespołu = główne koszty rotacji

Realny pułap F1 dla syntetycznego IBM HR Attrition (~16% klasy): 0.56–0.65 · Powyżej wymaga większego zbioru lub AutoML